

Metodos Numericos

Segundo cuatrimestre de 2017

6 de septiembre de 2017

Fotometria Estereo

1. Introducción Teórica

El foco de este trabajo practico es la resolucion de sistmas de ecuaciones lineales. La idea principal de la resolucion de dichos sistemas es despejar todas sus variables. En este trabajo pretendemos resolver sistemas lineales que tienen muchas incognitas lo cual hace que sea impractico intentar resolverlos en lapiz y papel. Razon por la cual utilizamos multiples metods numericos que simplifican la tarea de encontrar la solucion de estos sistemas. El metodo mas comun es el de eliminacion gaussiana que consiste en aplicar tres operaciones basicas una cantidad finita de veces para transformarlo al sistema de ecuaciones en otro equivalente (triangula el sistema) donde despejar las incognitas es una tarea trivial utilizando "backwards substitution". Estas tres operaciones basicas son multiplicar una fila por un escalar, sumar o restar un multiplo de una fila con otra y intercambiar filas. Siempre teniendo en cuenta que una fila no denota solo los coeficientes de las variables de una ecuacion sino tambien su termino independiente.

Aunque el metodo de eliminacion gaussiana es muy comun y bastante simple de implementar su complejidad temporal es $O(n^3)$ y cuando tenemos que resolver multiples sistemas de ecuaciones lineales esta complejidad no es tan buena. Pero si todo los sistemas lineales solo difieren en los terminos independientes, en algunos casos se puede usar el metodo de factorizacion LU donde la L es una matriz triangular inferior con unos en su diagonal y U es una matriz triangular superior. Las condiciones que tiene que cumplir un sistema lineal para garantizar la existencia de la factorizacion LU es que no tengamos que hacer un intercambio de filas en todas las iteraciones del algoritmo de gauss. Apesar de que encontrar la factorizacion LU de una matriz tiene costo $O(n^3)$, la resolucion del sistema $Ax = LUx = b$ tiene costo $O(n^2)$, ya que resolver este sistema es equivalente a resolver dos sistemas triangulados usando backwards substitution y forwards substitution. Esto hace que en las situaciones donde hay que resolver muchas veces el sistema $Ax = b$ para diferentes b sea mucho mas eficiente encontrar la factorizacion LU que usar el algoritmo de eliminacion de gauss. La demostracion detallada de porque los algoritmos de eliminacion gaussiana y el de factorizacion LU tienen complejidad $O(n^3)$ y $O(n^2)$ respectivamente, se puede ver en el libro Numerical Analysis de Burden.

La existencia de la factorizacion LU no esta garantizada para cualquier matriz. Dada una matriz invertible, las condiciones necesarias y suficientes para que exista la factorizacion LU son que no aparezca un zero como pivote en cada iteracion del algoritmo de eliminacion de gauss o que todas las submatrices principales sean invertibles.

Aunque la factorizacion LU no siempre existe, la factorizacion PLU si. Esta factorizacion consiste de tres matrices cuadradas P, L y U donde L es una matriz triangular inferior y U es una matriz triangular superior. La matriz P es designada una matriz de permutacion que es necesaria cuando al aplicar la eliminacion de gauss hace falta hacer intercambios de filas. Al igual que la factorizacion LU, la L de la PLU tiene que tener todos unos en su diagonal. Otra propiedad importante de la matriz P es que siempre existe su inversa, P^{-1} , y ademas $P^{-1} = P^t$.

Un problema que no debe pasar desapercibido cuando trabajamos con operaciones aritmeticas en la computadora es el de perdida de digitos significativos. Esto ocurre porque la computadora trabaja con aritmetica de digitos finitos lo cual quiere decir que la representacion de los numeros en la computadora tienen una cantidad de digitos finitos para ser representados. Los errores mas comunes son el error de redondeo, el de cancelacion catastrofica y el error que obtenemos al dividir por un numero muy pequeno. El error de redondeo ocurre cuando trabajamos con un numero cuya representacion requiere mas digitos de los que disponemos en la computadora. El error de cancelacion catastrofica surge cuando restamos dos numeros que son tan parecidos que se pierden demasiados digitos significativos. El problema que ocurre con una division donde el denominador es mucho mas pequeno que el numerador es que si el numerador tiene acumulado errores de operaciones anteriores la division por un numero mucho mas chico va a propagar esos errores.

En los algoritmos que nosotros implementamos abordar este problema es imprescindible ya que al computar el algoritmo de eliminacion de gauss se hacen alrededor de n^3 sumas, restas, divisiones y multiplicaciones, donde n es la cantidad de filas y columnas de la matriz asociada al sistema. La mejor forma que nosotros encontramos de acotar este tipo de errores es implementado el metodo de pivoteo parcial en nuestro algoritmo de eliminacion gaussiana. El pivoteo parcial consiste en que para cada iteracion del algoritmo el pivote sea el elemento mayor de la columna en la que se encuentra.

Otra factorizacion de matrices que utilizamos es la factorizacion LL^t , conocida como factorizacion de cholesky. Hay dos condiciones que tiene que cumplir una matriz para garantizar la existencia de esta factorizacion.

Primero que sea simétrica y segundo que sea definida-positiva. Se dice que una matriz es definida positiva cuando $x^t A x > 0 \forall x \in \mathbb{R}^{n \times n}$. Una propiedad importante para destacar es que si tenemos una matriz A simétrica que tiene factorización LU entonces se puede demostrar que A se puede escribir de la siguiente manera, $A = LU = LDL^t$. Si además todos los elementos de su diagonal son positivos entonces se puede demostrar que A tiene factorización chelosky, o sea que A se puede escribir de la siguiente manera $A = LL^t$. Cuando aplicable, esta factorización resulta ser bastante más eficiente que la factorización LU.

La estabilidad numérica de un sistema lineal es un concepto sumamente importante en el momento de considerar el error relativo que tiene la solución que obtenemos del sistema. Para ver si un sistema es estable hablamos del condicionamiento del sistema. A esta idea la cuantificamos utilizando el número de condición $\kappa(A) = \|A\| \|A^{-1}\|$. Se dice que un sistema lineal está bien condicionado si el número está lo más cerca posible de 1 y mal condicionado si es mucho más grande que 1. Aunque no hay ningún criterio exacto para saber cuál es el punto de quiebre entre mal y bien condicionado, según nuestras clases teóricas de la materia, si el número de condición es mayor a 10,000, usualmente se puede decir que el sistema está mal condicionado.

2. Desarrollo

En el desarrollo de este trabajo práctico lo primero que hicimos fue la calibración del sistema. Lo cual consistió en encontrar las coordenadas del punto más brillante de 12 imágenes de una esfera. Luego utilizamos las coordenadas del punto más brillante junto con la ecuación de la esfera para poder encontrar la dirección de la luz incidente a ella.

Para encontrar el punto más brillante, nuestra primera idea fue analizar uno por uno todos los píxeles de cada imagen hasta encontrar el píxel con la máxima intensidad en el rango de 1 a 255, pero nos dimos cuenta que esta no era la mejor estrategia. El problema que surgió al tratar de seleccionar el píxel más brillante de esta manera es que había más de un píxel con el máximo valor de brillo en una imagen y en estos casos decidimos elegir uno de todos los píxeles con mayor intensidad al azar. Esto llevó a que en muchos casos eligiésemos mal el punto más brillante. Lo que no nos habíamos dado cuenta al principio fue que las imágenes discretizan el espacio y esto es lo que lleva que haya más de un píxel que tengan la máxima intensidad de la imagen, pero esto no necesariamente quiere decir que la normal de todos estos puntos sean la dirección de la luz. Además no es muy lógico elegir el punto más brillante al azar ya que este representa la dirección de la iluminación la cual es única. Luego pensamos en que el brillo forma una aureola y que la esfera tiene algunas irregularidades sobre su superficie, entonces no alcanza con buscar el píxel más brillante, por lo tanto se utilizamos las vecindades para lograr agrandar el espectro. Una vez seleccionadas las coordenadas del punto más brillante de una imagen utilizamos la ecuación de la esfera, $r^2 = (x - x_0)^2 + (y - y_0)^2 + (z - z_0)^2$, para obtener las direcciones de la iluminación. De esta ecuación los parámetros que conocemos son las coordenadas (x_0, y_0) del centro de la esfera, el radio r y las coordenadas del píxel que consideramos más brillante (x, y) . Si C es el centro de la esfera y P el punto donde se encuentra el píxel más brillante, entonces el vector que representa la dirección de la iluminación es $C-P = (x_0 - x, y_0 - y, z_0 - (\sqrt{r^2 - (x - x_0)^2 - (y - y_0)^2} + z_0)) = (x_0 - x, y_0 - y, \sqrt{r^2 - (x - x_0)^2 - (y - y_0)^2})$.

Una vez obtenidos las direcciones de iluminación, el siguiente paso del desarrollo fue elegir las tres direcciones de luz para después obtener las normales. Nuestra idea fue elegir aquella combinación de direcciones que tengan el menor número de condición. Para hacer esto programamos un algoritmo que calcula todas las posibles permutaciones de tres vectores, teniendo 12 vectores para elegir, junto con el número de condición asociado a cada una de estas matrices. Hay que tener cuenta que al calcular las posibles permutaciones de las direcciones consideramos a una elección de tres vectores como un conjunto, ya que el número de condición no cambia si permutamos las columnas o filas de una matriz. El condicionamiento de una matriz, dado por su número de condición, nos pareció la mejor forma de escoger las direcciones ya que, por lo que aprendimos en clase una matriz mal condicionada es propensa a tener graves errores y no darnos soluciones del sistema en las cuales podemos confiar. Pensando en el número de condiciones en términos geométricos, también nos dimos cuenta de que el condicionamiento de una matriz va a mejorar a medida que las ecuaciones lineales de la matriz estén lo más lejano posible de ser paralelas, lo cual tiene sentido ya que tener iluminación dispersa ayuda a ver un objeto mejor en el mundo real. Nosotros suponemos que el error que vamos a obtener al calcular las normales va a estar directamente relacionado al condicionamiento de la matriz que utilizamos. Dicho de otra manera, el mejor gráfico de las normales va a estar dado por la matriz mejor condicionada. Para corroborar esto buscamos las matrices con el máximo y mínimo grado de condicionamiento y comparamos visualmente las diferencias entre los campos normales que obtuvimos utilizando cada una.

El procedimiento lo hicimos en C++. Para conseguir todas las combinaciones posibles de las direcciones de luz pusimos en una lista todas las filas (direcciones de luz) sin ninguna repetición. A esta lista se la recorre con 3 índices, los cuales nunca comparten el mismo valor y nunca se cruzan por lo tanto no se crean nuevas matrices con filas conmutadas, ni matrices con filas idénticas. Al mismo tiempo se le calcula el número de condición correspondiente a cada matriz y se guarda solamente la que posee el número de condición menor.

Con las tres direcciones de iluminación ya elegidas el siguiente paso del desarrollo es el cálculo de las normales en cada píxel. Esta es la etapa del trabajo práctico en la cual implementamos y utilizamos los algoritmos de eliminación de gauss y la factorización LU.


Nuestro algoritmo de eliminación gaussiana, hace n iteraciones donde n es la cantidad de filas de la matriz a triangular. En la i -ésima iteración toma el elemento a_{ii} como pivote. Si el pivote en cualquiera de las iteraciones es cero entonces no existe factorización LU pura, aunque si existe factorización PLU. Si el pivote no es cero el algoritmo hace otras k iteraciones donde k es la cantidad de filas que tiene por debajo. El algoritmo procede a calcular el múltiplo exacto por el cual tiene que multiplicar al pivote para poder eliminar al elemento, que este en la misma columna que el, y en la fila debajo si. Esto lo repite k veces, una vez para cada fila que se encuentra por debajo del pivote actual. Una vez terminadas las k iteraciones para el i -ésimo pivote, el algoritmo incrementa en 1 a i y pasa al siguiente pivote. Resulta evidente que los pivotes van a ser todos los elementos de la diagonal.

Obtener la factorización LU no es mas que guardar los múltiplos que utilizamos para diagonalizar una matriz en el algoritmo de eliminación gaussiana. Es importante notar que nosotros implementamos un algoritmo de factorización PLU donde la factorización LU es el caso específico donde la matriz P es la matriz identidad. Por lo cual, la complejidad temporal de obtener la factorización LU es igual a la complejidad del algoritmo de eliminación de gauss, la cual es $O(n^3)$.

Aunque sus complejidades son iguales, la diferencia se encuentra al momento de resolver varios sistemas. La eliminación gaussiana va a tener la misma complejidad cada vez que la utilizamos. En contraste, la factorización LU solo se obtiene una vez y luego solo se debe resolver dos sistemas triangulares, esto lleva a que su complejidad es $O(n^2)$. Como dice el enunciado del TP, los valores s_x, s_y, s_z , de la ecuación 5 no cambian pixel a pixel sino que solamente se modifica el valor de la intensidad en (x, y) para la imagen correspondiente I_i , y por lo tanto poseen la misma matriz pero con distinto término independiente. Por lo cual, si se encuentra una combinación de s_1, s_2 y s_3 que posea factorización LU se podría bajar sustancialmente la complejidad de obtener las normales de una imagen, ya que estas poseen una gran cantidad de pixeles.

Nuestra primer idea para tratar de comprobar nuestra hipótesis de que la factorización LU es mas rápida que la eliminación de gauss fue tomar distintos tamaños de matrices y triangularlos una vez con cada algoritmo para ver que método era mas rápido. Este experimento no pone a prueba nuestra hipótesis porque lo que intentábamos comprobar es que la factorización LU es mas rápida que la eliminación de gauss para resolver un sistema lineal después de la primera vez que se resuelve el sistema. Si resolvíamos una sola vez cada tamaño de matriz, ambos algoritmos tardarían lo mismo. Por lo tanto, decidimos hacer un experimento donde mantuvimos constante el tamaño del sistema lineal a resolver y lo que variamos en cada instancia de teste fueron las cantidades de términos independientes. Por ejemplo, la primera instancia resolvimos el sistema $Ax=b$ con 100 b diferentes y luego incrementamos la cantidad de términos independientes de 100 en 100, hasta llegar a 1000. Es importante remarcar que estos términos independientes fueron generados aleatoriamente con una función encontrada en la siguiente pagina:

SANTI TENES QUE PONER LA PAGINA ACA!!



3. Resultados

Aca escribimos los resultados.

4. Discusión

Aca escribimos la discusion.

5. Conclusiones

Aca escribimos las conclusiones.

6. Apéndices

Aca escribimos el apendices.

7. Referencias

Aca escribimos las referencias.